

Aproximación manual a la fotometría de apertura

Trabajo sobre el cúmulo abierto Messier 41

Tercera parte: Introducción al machine learning

Bruno Abello Laurent¹

¹Universidad de Los Andes, Departamento de Física, Colombia

Correo institucional: b.abello@uniandes.edu.co
Repositorio de GitHub: Repositorio del laboratorio

Resumen

Este informe es el segundo en una lista semanal cuyo objetivo es el acercamiento del autor a los métodos computacionales que se utilizan a menudo en el dominio de la astrofísica para definir la pertenencia de una estrella a un cúmulo abierto. El presente se enfoca en la determinación de pertenencia mediante un método de machine learning llamado HDBSCAN. La idea de este método es aprovechar parámetros como la densidad de puntos en un VPD para definir un cluster.

Palabras clave: Messier 41, Optimización, Vector Point Diagram, Probabilidad de pertenencia.

1 Introducción

“En palabras simples, nos quedamos cortos cuando se trata de determinar la pertenencia de un centroide a un cúmulo. Por lo tanto, a lo largo de la próxima semana se trabajará en los métodos que permiten una mejor determinación de pertenencia, pero esta vez con datos de GAIA, debido a la imposibilidad de definir movimientos propios de cuerpos celestes con una sola imagen.”

Con estas palabras se terminó el trabajo de la semana pasada. Efectivamente, nuestro método de estudio del cúmulo Messier 41 es bastante anticuado y, como observamos, muy bueno para detectar estrellas pero muy malo para decidir cuáles son efectivamente parte del cúmulo.

El día de hoy, por ende, decidimos avanzar en nuestros conocimientos y nuestros métodos. Ahora, con dos mil estrellas cuyos datos se descargaron de GAIA dr3, vamos a interesarnos a un nuevo tipo de diagrama, el VPD (Vector Point Diagram). Este nos permite visualizar un cluster de una manera mucho más clara, y esto se debe a la particularidad que los astrofísicos detectaron sobre los cúmulos después de la segunda guerra mundial, y es que los movimientos propios de sus estrellas son supremamente similares entre sí. Claro, esto es normal ya que todas esas estrellas nacieron al tiempo y están muy juntas, en la escala astronómica.

Mediante el estudio de los movimientos propios de las estrellas, junto con un ajuste de optimización de parámetros gaussianos, es posible determinar con una alta precisión qué estrellas pertenecen al cúmulo y qué estrellas pertenecen al campo. Este documento es un informe sobre

los problemas que presentó la implementación del método, sus limitaciones y sus poderosas fortalezas.

1.1 Objetivos

Los objetivos que tenemos, en términos simples, son los siguientes:

- Acercarnos a funciones computacionales cada vez más cercanas a lo que se utiliza en la astrofísica moderna.
- Empezar a familiarizarnos con las particularidades de los algoritmos de aprendizaje automático e iterativo.
- Aprender a leer un Vector Point Diagram y a interpretarlo.
- Aprender a interpretar los resultados probabilísticos del método de optimización de parámetros.
- Aprender a determinar qué es un problema en la programación y qué es un problema de los datos utilizados.

2 Procedimiento

Similarmente al laboratorio anterior, el procedimiento fue, al igual que el método, iterativo. A través de la prueba y error, se fue implementando una función de optimización de parámetros cada vez más ajustada a lo que se solía utilizar en la astrofísica. Esto se logró mediante la descarga de datos de GAIA en el área próxima a Messier 41 en un CSV, formato de fácil lectura en python. Para los valores

iniciales que toma la función se utilizaron unos valores encontrados por otro estudiante del curso, por lo cual se esperaban valores similares a estos.

Una vez estos valores obtenidos, se imprimen y se realizan varias gráficas: un nuevo VPD con el cúmulo resaltado, un histograma de probabilidades de pertenencia al cúmulo según cada estrella, y un CMD con las estrellas del cúmulo resaltadas.

El proceso se puede describir como iterativo, ya que, como era de esperarse, estuvo lleno de inconvenientes y de revisiones.

3 Problemas presentados y soluciones aplicadas

1. Por la cantidad de dudas que generan los parámetros ajustados, el código se hizo en tres documentos separados. El primero fue bastante sencillo, con errores de normalización y de cálculos. El siguiente arregló muchas cosas, pero no la normalización, y el último normalizó la gaussiana (por fin) y fue donde empezó a ser importante hablar de los demás problemas importantes.
2. El método no convergió a los valores esperados para la dispersión del cluster (0.2633 esperado vs 0.1637 obtenido), μ_x y μ_y del campo (esperados -0.7410 y 0.6275 vs -0.5297 y 0.3883 obtenidos), σ y del campo (7.3140 vs 6.6971) y n del campo (0.9455 vs 0.6798).
3. Debido a esto, se empezaron a aplicar una serie de controles y de maneras de ver si el método computacional estaba fallando.
 - a) No tenía un problema con el orden de interpretación y asimilación de los parámetros de las gaussianas, la función recibía todo en orden.
 - b) La normalización de la función no jugó un papel importante en devolver los parámetros a lo esperado, es más disminuyó el n_f en dos puntos.
 - c) La coloración por probabilidad de pertenencia del VPD no mostró estrellas alejadas del cúmulo con probabilidades remotamente altas de pertenecer (Fig. ??).
 - d) Los conteos con threshold de 0.9 o más de probabilidad de pertenecer muestran una cantidad de estrellas supremamente cercana a la encontrada por n_f y por demás métodos.
 - e) El histograma de probabilidades, si bien en escala logarítmica no parece tan drástico, es supremamente binario en escala normal en cuanto a pertenecer o no (Fig. ??).
 - f) los percentiles más altos (> 75) de la distribución de probabilidad dieron todos superiores a 0.9, confirmando la binariedad de la probabilidad de pertenencia.

- g) 529 estrellas tienen una probabilidad de 99 por ciento de pertenecer al cúmulo.
- h) La distancia en unidades de σ entre estas 529 estrellas no supera los 2.7 sigmas, por lo que no se tratan de un montón de outliers que la optimización no detectó (Fig. ??).
- i) La densidad de estrellas en el cúmulo decrece con la distancia en minutos de arco, lo que es esperable.
- j) La distribución de estrellas pertenecientes en un diagrama de declinación recta contra declinación disminuye conforme nos vamos alejando del centro, como se espera. (Fig. ??)

Con esto dicho, se considera que la mejor manera de presentar lo que siguió a continuación es en la sección de análisis de resultados.

3.1 Figuras de los problemas




Figura 1: Distancia, en sigmas de la distribución, entre las estrellas encontradas por la función de optimización de parámetros. Una distancia tan baja supone que los elementos sí pertenecen todos al cúmulo, sin excepciones reales.



Figura 2: Gráfico de probabilidad de pertenencia en función de cada estrella. Se aprecia que la distribución es supremamente binaria.

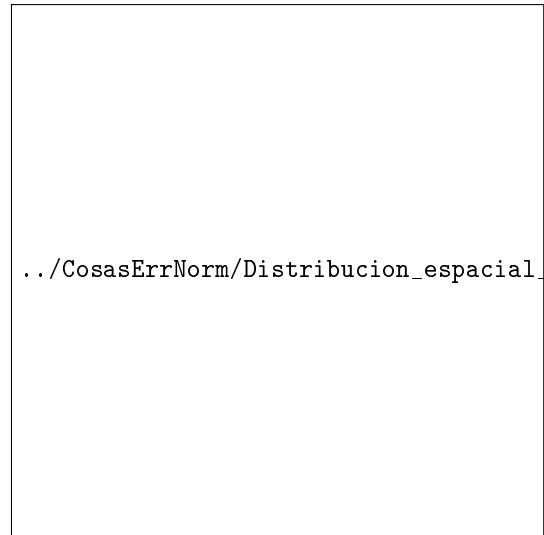


Figura 4: Mapa de la ascensión recta contra la declinación de cada elemento analizado. En anaranjado se muestran los pertenecientes al cúmulo, mostrando que, efectivamente, la mayoría se encuentran en una zona de alta densidad hacia el centro de la agrupación.

Otros resultados mencionados incluyen:
75, 90, 95, 99, 100 percentiles de Probabilidad
[0.99345065 0.9981174 0.99854258 0.99877663
0.99882815]
Estrellas con $P > 0.9$: 599
Estrellas con $P > 0.99$: 529
Tal y como los imprime el código: Código con errores Normalizado.py", disponible en la ruta Laboratorio 2/Código con errores Normalizado.py




Figura 3: VPD del primer set de datos utilizado. Se puede observar una gran densidad de estrellas en el cúmulo, con muy poquitas por fuera con probabilidades de pertenencia mucho más bajas

4 Resultados

Evidentemente, el set de datos presentaba algún problema: El cluster se ve perfectamente y está extrañamente bien definido, con unas probabilidades altísimas para muchas estrellas. Después de tantas pruebas, la única respuesta lógica era que el set de datos tenía algo extraño. Gracias al archivo de datos de otro compañero, se hicieron las mismas pruebas, corriendo el mismo código, para el nuevo archivo. Estas pruebas están en la ruta Laboratorio 2/Lab 2 Otro csv. El resultado fue flagrante: 5 por ciento de pertenencia al cúmulo por parte de la población, valores de optimización tales y como se esperaban, unas 100 estrellas en el cúmulo contra las más de 500 encontradas anteriormente, pocas estrellas con una probabilidad tan alta de pertenecer al cúmulo, pero una buena población por encima de 0.7. (Fig. ??) Entonces, se aplicó un test directamente a los archivos .csv para determinar su correlación. Resultado, una sola estrella presente entre los dos archivos. Todo el análisis inicial, que duró varios días, se había hecho sobre una región del cielo que, sí, efectivamente, posee un cúmulo, pero que claramente no es Messier 41. Las semejanzas son, sin embargo, impresionantes, ya

que ambos cúmulos se encuentran más o menos en la misma región de sus respectivos VPD, y algunos de sus datos de optimización son muy similares.



Figura 5: Diagrama de probabilidad de pertenencia en función de cada estrella para el nuevo set de datos en escala logarítmica. Una comparación al histograma sin esta escala se encuentra en el anexo. ??

Ya con el set de datos correcto, se puede empezar a hablar mejor de lo que encuentra el código. Para simplificar las cosas, y no tener que buscar manualmente en un VPD cada una de las estrellas coloreadas, se realizó un VPD que tome las estrellas con probabilidad superior a un threshold y las muestre. De esta manera, se obtiene un VPD de buena calidad que muestra correctamente el cluster y sus alrededores. (Fig. ??). Se ven claramente las estrellas que pertenecen y las que pueden pertenecer, y el CMD ya presenta resultados en una región aceptable y esperada. (Fig. ??). Un par de preguntas resultan de la distribución de probabilidades, ya que es cierto que no es una distribución tan binaria como se espera. (Fig. ??). Sin embargo, se obtiene en el VPD un resultado coherente y que parece un cúmulo bien definido.




Figura 6: VPD de los miembros con $P > 0.7$ de pertenecer al cúmulo. Se observa una densidad mucho menor de estrellas que en (Fig. ??). Asimismo, se ve que ciertas estrellas dentro de la zona resaltada no tienen una probabilidad tan alta de pertenecer al cúmulo.

Otro problema notable es el gráfico de ascensión recta contra declinación de este set de datos. (Fig. ??). Lo que empezó como una manera de asegurarse de que el "cúmulo" de 500 estrellas era de verdad un cúmulo terminó siendo una herramienta útil para dudar del cúmulo M41. Se supone que, en este gráfico, los valores correspondientes a las estrellas pertenecientes al cúmulo deberían estar en una región cercana, y cercana al centro del gráfico. Sin embargo, lo que presenta este caso es que no hay tanta claridad en cuanto a dónde está el cúmulo en este mismo. Algunas estrellas están muy arriba, otras muy abajo, otras en el medio, casi como una diagonal ancha que atraviesa el diagrama de abajo a la izquierda a arriba a la derecha. También se realizó un estudio de la distancia en sigmas entre la población con más de 0.7 de probabilidad de pertenecer al cúmulo en cuanto a sus proper motions, y se encontraron un par de estrellas por encima de los 5 sigmas, lo que indica que el cúmulo ya se está extendiendo un poco por encima de lo que se ve normalmente. (Fig. ??).



Figura 7: CMD del nuevo set de datos. Se observa una población mayoritariamente en la parte inicial de la secuencia principal, tal y como se esperaba al iniciar este laboratorio. Comparado al CMD viejo, se nota que los resultados cuadran con lo esperado. (Fig. ??)



Figura 8: Diagrama de declinación contra ascensión recta. Comparado a (Fig. ??), se observa una zona diagonal dibujada, a comparación de la densidad central que se diluye hacia los bordes. Esto significa que nuestro cúmulo es ahora mucho más pequeño y menos definido.

Por último, solamente 3 estrellas pertenecen con más de 99 por ciento de confianza, y solo 79 con más del 70. Estos números son bastante contrariantes, ya que se esperarían unos 100 miembros en el cluster entre lo reportado en la literatura [?] y el número, bastante rudimentario,

encontrado en el estudio anterior de 111 centroides. Sin embargo, el CMD muestra muchos miembros en la zona de enanas blancas, antes de entrar a la secuencia principal, y pocos miembros en la misma, lo que es de esperarse en un estudio como este. Es decir, el resultado obtenido, si bien es poco satisfactorio, es lo que se esperaba obtener, y posiblemente los miembros de la secuencia principal que no aparecen en nuestro CMD son precisamente los que faltan en nuestro conteo probabilístico.



Figura 9: Histograma de la distancia en sigmas entre las estrellas con $P > 0.7$ de pertenecer a M41. Se observan distancias más grandes que en el anterior, (Fig. ??) pero se siguen teniendo muchas estrellas cercanas a lo esperado y solo unas cuantas por encima de los 5 sigmas, lo que significa que, a pesar de estar más diluido que el anterior, sigue siendo un cúmulo bien definido.

5 Conclusiones

Es, entonces, evidente que nuestro método se queda una vez más muy corto para poder determinar la pertenencia de una estrella a un cúmulo, como ya se ha dicho. Por una parte, no se encuentran todas las estrellas que se esperaban. Esto no es de esperarse, ya que, normalmente, se descargó la región del cielo en la que se sabe que está el cluster. Sin embargo, es el método que implementamos lo que más sorpresas da. Como se dijo, presenta problemas de definición de pertenencia, aunque muchos menos que el de hace una semana. Asimismo, presenta un bias en los miembros encontrados hacia la base de la secuencia principal, lo que conocemos como incorrecto ya que el cúmulo M41, bien estudiado, presenta miembros a lo largo de la secuencia principal.

Gracias a solo dos semanas de implementación computacional, encontramos las razones por las cuales ningún método tradicional de computación resulta ser suficiente para estudiar cúmulos galácticos. A partir de la próxima semana, por ende, optamos por iniciar nuestra investigación en el territorio del Machine Learning. Para permitir-

nos un estudio a profundidad, descargaremos un nuevo set de datos con muchísimos más datos. Nótese la robustez de los métodos de Machine Learning, que podremos importar miles de datos y aún así encontrar nuestro cúmulo bien definido. Eso esperamos, al menos.

Comentarios al margen

Aunque no sea del todo necesario hablarlo, es cierto que es bueno mirar a las razones de por qué el autor trabajó por tanto tiempo con un set de datos equivocado sin saber que no eran datos correctos. El ejemplo estrella es la comparación de (Fig ??) y (Fig ??), donde la similitud en la región de los VPD pudo inducir un falso sentido de seguridad con respecto a los datos en el autor. Además, es cierto que el autor nunca pensó haber descargado datos erróneos, por lo que podía sentirse seguro del contenido de su archivo.

El leve retraso en la entrega de este documento se debe en parte a que esta confusión de datos generó la necesidad de comparar los archivos uno a uno. El archivo Laboratorio 2/Lab2Otrocsv/comparacióncsv.py contiene todas las pruebas que se realizaron para determinar la similitud de ambos documentos. Es también importante mencionar que, debido a la magnitud de estos informes, el autor tuvo que migrar su medio de trabajo a uno local para poder tratar la cantidad de imágenes que se ponen en este documento. Temas de documentación, citación y rutas en formato LaTeX causaron retrasos significantes en el trabajo del autor.

Imágenes adicionales



Figura 10: Diagrama de probabilidad de pertenencia en función de cada estrella para el nuevo set de datos. Se observa a duras penas la diferencia entre la pertenencia más alta al cúmulo y las probabilidades inferiores.




Figura 11: CMD del primer set de datos estudiado. Se puede evidenciar una población perteneciente casi exclusivamente perteneciente a La secuencia principal, algo que no es lo esperado cuando se trabaja con este método de optimización de parámetros.




Figura 12: VPD coloreado con el cluster del primer set de datos estudiado.



../Lab20trocsv/CosasErrNorm/VPDColoreado.png

Figura 13: VPD coloreado con el cluster del segundo set de datos estudiado.