

Aproximación manual a la fotometría de apertura

Trabajo sobre el cúmulo abierto Messier 41

Tercera parte: Introducción al machine learning

Bruno Abello Laurent¹

¹Universidad de Los Andes, Departamento de Física, Colombia

Correo institucional: b.abello@uniandes.edu.co
Repositorio de GitHub: Repositorio del laboratorio

Resumen

Palabras clave: Messier 41, HDBSCAN, Vector Point Diagram, Color Magnitude Diagram.

1 Introducción

El presente informe se puede ver como la culminación de varias semanas de trabajo sobre los métodos computacionales que se utilizaron históricamente en el estudio de los cúmulos abiertos. A través de métodos cada vez más refinados, nos hemos acercado al uso del machine learning para identificar cúmulos abiertos entre los datos que obtienen las herramientas más poderosas de la humanidad para detectar y catalogar cuerpos celestes en el universo.

Como una prueba de lo poderoso pero poco comprendido que puede ser un método de machine learning, trabajamos con todos los cuerpos a 100 pársecs alrededor de nuestro sol, con el fin de encontrar clusters en este espacio. Lo interesante de este estudio es que la humanidad ya ha estudiado bien esta región, y ha encontrado dos cúmulos, Coma y Hyades. Nosotros no queremos limitarnos a estos dos, y buscaremos cualquier indicio de que un tercero o más cúmulos se encuentran en esta región. Es decir, por primera vez nos interesamos a un trabajo de exploración y no a uno de encontrar algo que sabemos que está ahí.

Las explicaciones del método que se utiliza, HDBSCAN, ya se dieron en semanas anteriores, por lo que, para esta ocasión, podemos ser más directos con nuestros resultados y otros detalles.

1.1 Objetivos

Los objetivos que tenemos, en términos simples, son los siguientes:

- Implementar una manera de analizar cientos de miles de datos de GAIA
- Implementar formas, simples o avanzadas, de determinar qué es un cluster real

- Entender las limitaciones que tiene el Machine Learning
- Realizar un análisis manual que de un paso más allá de lo que hace un computador.

2 Procedimiento

Teniendo en cuenta estos objetivos, proceder fue bastante directo: al hablar con la clase, se determinó que se podía cortar el cielo en 64 porciones iguales y analizar cada una por separado. Resulta que HDBSCAN tiene un crecimiento altísimo en tiempo con la cantidad de datos que se le proporcionan, por lo que analizar pequeñas celdas de 5000-10000 estrellas es mucho mejor que analizar todo el cielo al tiempo.

Acto seguido, se empezaron a implementar cortes y restricciones a la función de análisis, de manera que no se tuviera que graficar todo el cielo por un falso cúmulo de 30000 estrellas. Además, se realizó a posteriori una gráfica de todo el cielo, en ascensión recta contra declinación, para ver en dónde y qué forma tienen los cúmulos detectados.

El como se llegó a la función final y el cómo se resolvió hacer todo esto pertenece a la sección siguiente.

3 Problemas presentados y soluciones aplicadas

1. Uno de los primeros problemas encontrados fue qué presentar como resultado. Se resolvió que lo mejor era presentar dos CMDs y dos VPDs, unos sin silueta y otros dos con ella, además de un histograma con la distribución de miembros por cluster encontrado sobre la distancia.

2. El segundo problema fue darse cuenta de que hay muchos cúmulos encontrados por HDBSCAN que son, de alguna manera, basura. Tienen 60, o 20000 miembros, y están muy lejos de ser un cúmulo real. La solución, sencilla, es cortar cúmulos con menos de 90 miembros o más de unos 1050 miembros, para conservar los que, al menos, tienen un semblante real.
3. Posteriormente, se encuentra el siguiente problema, y es que muchos cúmulos encontrados no se comportan, en su extensión, como un cúmulo real: son enormes. Por ende, se elimina un cúmulo que tenga más de 34 pársecs de extensión.
4. Además de los problemas anteriores, un problema más elusivo se puede encontrar en la forma de la distribución del cúmulo. Se espera que sea gaussiano, pero la mayoría del tiempo se obtiene una pendiente creciente, que asumimos infinita en el espacio más allá de los 100 clusters: un cono de estrellas hacia el infinito. Para eliminar estos cúmulos, se implementó un corte un poco curioso: calcular la pendiente de los datos y, si supera un threshold, eliminar el cúmulo.
5. El lector podrá comprender que esto no elimina todos los cúmulos como se quiere, y se siguen obteniendo datos. Sin embargo, resultó que, para el estudiante, implementar cortes automáticos correctos empezó a resultar complicado y poco fructífero. Por ende, decidió que iba a realizar un ajuste gaussiano a cada cúmulo restante, para luego revisar manualmente qué tan convincente era el ajuste.
6. Por aparte, también hay que notar algo muy importante, y es que los datos que se utilizaron no incluían las regiones de Coma y Hyades. Por ende, estos datos se volvieron a añadir gracias a un código de python, y se sumaron al análisis. De esta manera, se sabe cómo debería lucir un cúmulo real con la presentación que se instauró para hacer el análisis.

Nótese, primeramente, que el volver a añadir los datos de Hyades y Coma resultó en la superposición de regiones en el mapa. Por ende, se ven en el mapa dos regiones especiales, lo que no es muy grave pero sí amerita una explicación previa al análisis serio de los datos. Por otro lado, y como dato o consejo para el lector, se ha de entender que los pasos propuestos en la lista anterior están aplicados en el código en ese orden exactamente. Esto es debido a que los cortes fuertes eliminan lo realmente innecesario, y lo difícil de procesar, como un cúmulo muy extenso o un cúmulo con 20000 miembros, dejando así los métodos más exigentes, como el cálculo de pendiente o el ajuste de gaussiana, a una serie reducida, y más real, de cúmulos. Así, el código es mucho más rápido.

4 Resultados

Como podrá entender el lector, los resultados de este informe son, en cierta medida, subjetivos. Sí, hay muchos

criterios que nos permiten decidir si algo es o no es un cúmulo de manera objetiva, pero lo cierto es que no todo se resuelve con código. Esta sección es, entonces, una presentación sucinta, comparativamente hablando, de los resultados encontrados. O sea, de lo más prometedor.

Primeramente, observemos los resultados de los clusters conocidos: Coma y Hyades. Los resultados obtenidos se presentan en PONER Y REFERENCIAR GRÁFICAS DE COMA Y HYADES. Son, adicionalmente, las regiones especiales del cielo en la figura PONER EL CIELO COMPLETO. Se observa de los CMDs, VPDs y distribuciones de distancia el comportamiento estándar de un cúmulo bajo las condiciones impuestas por el código. Los comportamientos de la distribución del cúmulo en función de la distancia son normales, se observa muy poco ruido en los CMDs, y una región bien comportada en los VPDs. Curiosamente, en el estudio de EL QUE ESTÁ MÁS LEJOS, se obtiene un cúmulo más pequeño. Sin embargo, por el número de miembros encontrado, CITAR CUANTOS SON es probable que este cumulo haga parte del cúmulo más grande ya conocido.

El trabajo más importante, sin embargo, es preguntarnos si existen cúmulos en esta esfera alrededor del sol que no conocemos. Ya se explicaron los cortes automáticos a los cúmulos encontrados por machine learning, y ahora toca explicar aquellos que se juzgan manualmente. Nótese que de 64 regiones, las regiones 2, 7, 14, 19, 20, 22, 25, 31, 35, 39, 42, 44, 47, 48, 51, 52 y 62 son las únicas que presentan algún tipo de resultado medianamente coherente. O sea 17 regiones de 64. De estas 17 regiones, visibles en la figura CITAR MAPA, varias pueden ser descartadas por una u otra razón.



Figura 1: Compilación de los CMDs obtenidos con el estudio de los datos mediante HDBSCAN. El cluster Messier 41 es, se espera, el cluster 1 tal y como lo marca el método.

5 Conclusiones

Comentarios al margen

Referencias