

Aproximación intensiva a los métodos con Machine Learning en la Astrofísica

Trabajo sobre la esfera de 100 parsecs alrededor del sol
Último en la serie del descubrimiento de los métodos modernos de la Astrofísica

Bruno Abello Laurent¹

¹Universidad de Los Andes, Departamento de Física, Colombia

Correo institucional: b.abello@uniandes.edu.co
Repositorio de GitHub: Repositorio del laboratorio

Resumen

El presente informe es un estudio supremamente cualitativo y a criterio del autor sobre los resultados del uso de HDBSCAN para explorar la posible existencia de otros cúmulos a menos de 100 pársecs del sol además de COMA Berenice y Hyades. Se encontraron dos posibles candidatos, después de un análisis exhaustivo y manual de los resultados obtenidos gracias al Machine Learning.

Palabras clave: COMA Berenice, Hyades, HDBSCAN, Mapa estelar, Exploración libre.

1 Introducción

El presente informe se puede ver como la culminación de varias semanas de trabajo sobre los métodos computacionales que se utilizaron históricamente en el estudio de los cúmulos abiertos. A través de métodos cada vez más refinados, nos hemos acercado al uso del machine learning para identificar cúmulos abiertos entre los datos que obtienen las herramientas más poderosas de la humanidad para detectar y catalogar cuerpos celestes en el universo.

Como una prueba de lo poderoso pero poco comprendido que puede ser un método de machine learning, trabajamos con todos los cuerpos a 100 pársecs alrededor de nuestro sol, con el fin de encontrar clusters en este espacio. Lo interesante de este estudio es que la humanidad ya ha estudiado bien esta región, y ha encontrado dos cúmulos, Coma y Hyades. Nosotros no queremos limitarnos a estos dos, y buscaremos cualquier indicio de que un tercero o más cúmulos se encuentran en esta región. Es decir, por primera vez nos interesamos a un trabajo de exploración y no a uno de encontrar algo que sabemos que está ahí.

Las explicaciones del método que se utiliza, HDBSCAN, ya se dieron en semanas anteriores, por lo que, para esta ocasión, podemos ser más directos con nuestros resultados y otros detalles.

1.1 Objetivos

Los objetivos que tenemos, en términos simples, son los siguientes:

- Implementar una manera de analizar cientos de miles de datos de GAIA
- Implementar formas, simples o avanzadas, de determinar qué es un cluster real
- Entender las limitaciones que tiene el Machine Learning
- Realizar un análisis manual que de un paso más allá de lo que hace un computador.

2 Procedimiento

Teniendo en cuenta estos objetivos, proceder fue bastante directo: al hablar con la clase, se determinó que se podía cortar el cielo en 64 porciones iguales y analizar cada una por separado. Resulta que HDBSCAN tiene un crecimiento altísimo en tiempo con la cantidad de datos que se le proporcionan, por lo que analizar pequeñas celdas de 5000-10000 estrellas es mucho mejor que analizar todo el cielo al tiempo.

Acto seguido, se empezaron a implementar cortes y restricciones a la función de análisis, de manera que no se tuviera que graficar todo el cielo por un falso cúmulo de

30000 estrellas. Además, se realizó a posteriori una gráfica de todo el cielo, en ascensión recta contra declinación, para ver en dónde y qué forma tienen los cúmulos detectados.

El como se llegó a la función final y el cómo se resolvió hacer todo esto pertenece a la sección siguiente.

3 Problemas presentados y soluciones aplicadas

1. Uno de los primeros problemas encontrados fue qué presentar como resultado. Se resolvió que lo mejor era presentar dos CMDs y dos VPDs, unos sin silueta y otros dos con ella, además de un histograma con la distribución de miembros por cluster encontrado sobre la distancia.
2. El segundo problema fue darse cuenta de que hay muchos cúmulos encontrados por HDBSCAN que son, de alguna manera, basura. Tienen 60, o 20000 miembros, y están muy lejos de ser un cúmulo real. La solución, sencilla, es cortar cúmulos con menos de 90 miembros o más de unos 1050 miembros, para conservar los que, al menos, tienen un semblante real.
3. Posteriormente, se encuentra el siguiente problema, y es que muchos cúmulos encontrados no se comportan, en su extensión, como un cúmulo real: son enormes. Por ende, se elimina un cúmulo que tenga más de 34 pársecs de extensión.
4. Además de los problemas anteriores, un problema más elusivo se puede encontrar en la forma de la distribución del cúmulo. Se espera que sea gaussiano, pero la mayoría del tiempo se obtiene una pendiente creciente, que asumimos infinita en el espacio más allá de los 100 clusters: un cono de estrellas hacia el infinito. Para eliminar estos cúmulos, se implementó un corte un poco curioso: calcular la pendiente de los datos y, si supera un threshold, eliminar el cúmulo.
5. El lector podrá comprender que esto no elimina todos los cúmulos como se quiere, y se siguen obteniendo datos. Sin embargo, resultó que, para el estudiante, implementar cortes automáticos correctos empezó a resultar complicado y poco fructífero. Por ende, decidió que iba a realizar un ajuste gaussiano a cada cúmulo restante, para luego revisar manualmente qué tan convincente era el ajuste.
6. Por aparte, también hay que notar algo muy importante, y es que los datos que se utilizaron no incluían las regiones de Coma y Hyades. Por ende, estos datos se volvieron a añadir gracias a un código de python, y se sumaron al análisis. De esta manera, se sabe cómo debería lucir un cúmulo real con la presentación que se instauró para hacer el análisis.

Nótese, primeramente, que el volver a añadir los datos de Hyades y Coma resultó en la superposición de regiones en el mapa. Por ende, se ven en el mapa dos regiones

especiales, lo que no es muy grave pero sí amerita una explicación previa al análisis serio de los datos. Por otro lado, y como dato o consejo para el lector, se ha de entender que los pasos propuestos en la lista anterior están aplicados en el código en ese orden exactamente. Esto es debido a que los cortes fuertes eliminan lo realmente innecesario, y lo difícil de procesar, como un cúmulo muy extenso o un cúmulo con 20000 miembros, dejando así los métodos más exigentes, como el cálculo de pendiente o el ajuste de gaussiana, a una serie reducida, y más real, de cúmulos. Así, el código es mucho más rápido.

4 Resultados

Como podrá entender el lector, los resultados de este informe son, en cierta medida, subjetivos. Sí, hay muchos criterios que nos permiten decidir si algo es o no es un cúmulo de manera objetiva, pero lo cierto es que no todo se resuelve con código. Esta sección es, entonces, una presentación sucinta, comparativamente hablando, de los resultados encontrados. O sea, de lo más prometedor.

Primeramente, observemos los resultados de los clusters conocidos: Coma y Hyades. Los resultados obtenidos se presentan en (Figs: 1, 4). Son, adicionalmente, las regiones especiales del cielo en la figura (Fig: 5). Se observa de los CMDs, VPDs y distribuciones de distancia el comportamiento estándar de un cúmulo bajo las condiciones impuestas por el código. Los comportamientos de la distribución del cúmulo en función de la distancia son normales, se observa muy poco ruido en los CMDs, y una región bien comportada en los VPDs. Curiosamente, en el estudio de COMA, se obtiene un cúmulo más pequeño. Sin embargo, por el número de miembros encontrado en este, es probable que dicho cumulo haga parte del cúmulo más grande ya conocido.

El trabajo más importante, sin embargo, es preguntarnos si existen cúmulos en esta esfera alrededor del sol que no conocemos. Ya se explicaron los cortes automáticos a los cúmulos encontrados por machine learning, y ahora toca explicar aquellos que se juzgan manualmente. Nótese que de 64 regiones, las regiones 2, 7, 14, 19, 20, 22, 25, 31, 39, 42, 44, 47, 48, 51, 52 y 62 son las únicas que presentan algún tipo de resultado medianamente coherente. O sea 16 regiones de 64. De estas 16 regiones, visibles en la figura (Fig: 5), varias pueden ser descartadas por una u otra razón.

Hay que empezar estos descartes por notar que a excepción de Coma y Hyades, ninguno de los cúmulos encontrados tienen una distribución en RA y DEC similar a la de un cúmulo. Todas las estrellas están dispersas a lo largo de la celda, por lo que primero hablaremos de las anomalías de este estilo: Las regiones 19, 20 y 44. La concentración de estrellas en 19 está acumulada hacia la celda 20, por lo que juntos podrían ser un semblante de cúmulo. Sin embargo, no se encuentran en el mismo punto del espacio, ya que uno está centrado hacia los 62 pársecs y otro hacia los 85 (Figs: 11, 12). Además, el cúmulo en la celda 19 es

más extenso que 30 pársecs, y su CMD tiene mucho ruido en la zona inferior, junto con una secuencia principal pobre. Sumado a esto, la distribución en el mapa estelar de la celda 20 no tiene coherencia con la de la celda 19. En definitiva, juntas no forman un cúmulo, y por separado 19 tiene demasiado ruido y 20 tiene una mala distribución en distancia, sin hablar de que la mayoría parece ser ruido de GAIA, puesto que si fuera un cúmulo joven, no estaría tan esparcido en el mapa estelar.

La celda 44 muestra, por su parte, una acumulación de estrellas enorme cerca a las celdas 41, 53 y 52. Sin embargo, estas celdas no tienen cúmulos coherentes con los de la celda 44. Además, el cúmulo 3 encontrado en esta celda es enorme (Fig: 18), con una mala distribución en distancia y muchísimo ruido en el CMD, el primer cúmulo no es muy diferente: es casi demasiado pequeño, pero está muy bien distribuido en distancia y en el VPD. Además, (Fig: 2), la distribución de este cúmulo en el mapa espacial es demasiado extensa para un cúmulo recién nacido. Es decir, la celda 44 sólo contiene ruido y ni la celda 44, ni la 19 ni la 20 encontraron algún cúmulo prometedor. Con eso, podemos movernos a las siguientes 13 regiones, todas mal distribuidas en el mapa estelar.

Empezemos esta siguiente parte por la celda número 7 (Fig: 9). Ambos tienen ruido en el CMD, pero una buena secuencia principal. El cúmulo 1 presenta huecos en su secuencia, pero no tiene una mala extensión en distancia. Sin embargo, entre el ruido y los huecos en la secuencia principal, este no parece cúmulo. Por otro lado, el cúmulo 0 no presenta problemas en el CMD, y tiene un buen VPD. Sin embargo, es relativamente pequeño en extensión y si es un cúmulo, se necesitaría expandir la búsqueda en ese sector a más de 100 pársecs para estar seguros. A su lado, el cúmulo de la región 14 tiene mucho ruido (Fig: 10), huecos en su secuencia principal y una distribución de distancia poco coherente para un cúmulo, debido a sus varios picos locales. Por ende, la región 14 no es un cúmulo real. A excepción de los comentarios sobre el VPD, se pueden aplicar los mismos comentarios a la sección 19 (Fig: 11), que además resulta más extenso que 30 pársecs. Los mismos comentarios de antes se pueden aplicar al sector 20 (Fig: 12). Con esto, hemos eliminado 6 zonas de manera definitiva, y una zona tiene un semblante de cúmulo.

La celda 22 parece otra historia (Fig: 13): poco ruido en el CMD, un VPD relativamente centrado, y una distribución en extensión decente. Probablemente, ir a más de 100 pársecs complete el VPD, aunque dejaría algunos huecos curiosos en la distribución de extensión. Se encuentra algo prometedor en esta región, y los mismos comentarios se podrían aplicar a la región 25, de no ser por sus huecos en la distribución de distancia, y sus picos regionales en 92 y 99 pársecs (Fig: 14). Se podría pensar que la 31 también es prometedora, pero tiene unos huecos importantes en su distribución espacial, por lo que no la vamos a tener en cuenta (Fig: 15). Por último, la región 39 tiene poco ruido y una buena distribución general en VPD y en distancia, aunque sea pequeño en extensión (Fig: 16). Esta

región entrega algo prometedor. Recapitulando, las celdas 7-0, 22 y 39 muestran algo prometedor, entre las 10 zonas comentadas.

La celda 42 es un caso similar al de los demás: todo muy suave, y la extensión en distancia parece mostrar que un poco más allá de los 100 pársecs encontraremos el resto del cúmulo (Fig: 17). La celda 44 es todo lo contrario: demasiado ruido y poco espacio para argumentar que existe un cúmulo real (Fig: 18). Con solo el ruido en el CMD y la distribución en distancia del cúmulo 3 ya se puede decir que no es real, y si el cúmulo 1 no pareciera ser solo ruido, se podría argumentar que es un cúmulo joven con pocas estrellas, aún en formación. Sin embargo, es poco probable que sea el caso, por lo que se descarta totalmente esta región.

Siguiendo con la región 47, esta parece presentar un cúmulo tentador, si no fuera porque tiene dos picos en su distribución en distancia (Fig: 19). Tanto su CMD como su VPD son buenos y presentan una estructura adecuada para lo que es un cúmulo como lo hemos encontrado por este método. Asimismo, la celda 48 podría tener el resto de su cúmulo, que completaría sus pequeños huecos en el CMD y en el VPD, por encima de los 100 pársecs (Fig: 20). Sin embargo, es una distribución poco convincente en distancia, debido a los valles inusuales que presenta. Por ende, nos quedamos con estos para una discusión posterior.

La celda 51 es un caso particular, ya que presenta dos cúmulos que, de no ser por su separación en el VPD, podrían constituir uno solo (Fig: 21). Debido a que no consideramos que dos cúmulos distintos puedan existir en el mismo espacio, no consideramos estos datos como un cúmulo real. Misma conclusión para la región 52, debido a su VPD disperso, sus huecos en su CMD y su distribución en distancia poco coherente (Fig: 22). Para finalizar la revisión general de los cúmulos, la región 62 nos deja con un amargo sabor de boca, ya que a pesar de su buena forma de distribución en distancia, no tiene la extensión adecuada como para ocultarnos algo después del corte de los datos, tiene un VPD disperso y un CMD entrecortado y con una buena cantidad de ruido (Fig: 23). Nos quedamos con las regiones 7-0, 22, 39, 47 y 48, cinco regiones de las 16 iniciales.

Pero entonces, ¿Qué podemos hacer para decidir si son buenos cúmulos o no? Primero, veamos por qué siguen acá: En las regiones 7, 22, 47 y 48 dijimos que podrían ser bien completados con datos a más de 100 pársecs (Figs: 9, 13, 16, 19, 20). Hablemos entonces del 39, puesto que es el único sin este problema. A pesar de un hueco en la secuencia principal, cerca a (1.25, 12), el poco ruido del CMD y la consistencia del VPD nos hacen considerar esto como un verdadero cúmulo, incluso aunque parezca que los valores de silueta descartan el brazo derecho que aparece en el VPD. Nos quedamos con este cúmulo.

Ahora tenemos que hablar de los otros 5. Es cierto que podríamos descargar más datos y verificar que estos datos corresponden efectivamente a un cúmulo. Sin embar-

go, para hacer aprender a ejercer criterio propio sobre los resultados, analizaremos esto sin descargas extra. El cúmulo 0 de la región 7 tiene todo para ser un cúmulo de verdad: no tiene huecos en su secuencia principal, el ruido del CMD es mínimo, tiene un VPD compacto y una distribución en distancia lo suficientemente corta (menor a 15 pársecs) que deja pensar que del otro lado se encuentran unos 15 pársecs de cúmulo. También nos quedamos con este. Los comentarios para la celda 22 son levemente distintos. Aunque tenga buenos CMD y VPD, su distribución disminuye mucho para tener algo por detrás de los 100 pársecs. Además, parece tener dos picos, debido a un valle entre los 90 y los 94 pársecs, por lo que no nos quedaremos con este cúmulo.

Por otro lado, no conservaríamos la celda 47. Aunque tenga unos buenos diagramas, su distribución en distancia simplemente no es convincente. Tiene un pico en 85 pársecs y otro cerca de los 97, con un valle en el medio. Si aumentamos la distancia visible, no se completaría una forma gaussiana aceptable. Por último, la sección 48 tiene un problema similar. Presenta picos y valles poco convincentes, sumado a su rápido descenso en miembros cerca de los 100 pársecs. Es decir, no parece tener miembros más allá. Tampoco lo conservamos.

Vemos entonces que de 16 regiones, con poco más de 16 cúmulos posibles, nos quedamos con las regiones 39 y 7 es decir dos de dieciseis (Figa: 16, 9).

5 Conclusiones

En conclusión, este ejercicio de exploración nos permitió entender mucho mejor cómo funcionan los resultados encontrados por métodos de machine learning en el dominio de la astrofísica. Además, se pudo realizar un buen trabajo de ejercicio del criterio del científico, puesto que cada resultado encontrado vino acompañado de un análisis detallado para la determinación adecuada de su significado.

El método encontró, al final, dos posibles cúmulos en la región de 100 pársecs alrededor de nuestro sol, aunque sea suponiendo que la distribución de los resultados en el mapa estelar no son tan importantes. Sin embargo, el objetivo de esta exploración siendo aprender del análisis de resultados de Machine Learning más que de estar seguros de que lo encontrado es sí o sí un cúmulo, se puede concluir que este ejercicio fue exitoso.

Comentarios al margen

El envío de este documento se realiza algunos minutos tarde debido a que no se habían organizado correctamente todas las imágenes.




Figura 1: Resultados obtenidos para Hyades. Se observan una excelente distribución en distancia, una buena secuencia principal de CMD y una buena distribución de VPD




Figura 2: Distribución espacial en el mapa estelar del cúmulo 1 de la celda 44. Se observa una población repandida, como una simulación pequeña del cúmulo 3, encontrado más atrás en el espacio de esta misma celda. (Fig: 3)




Figura 3: Distribución espacial en el mapa estelar del cúmulo 3 de la celda 44. Se observa una población compacta cerca a la esquina inferior izquierda, con algunos miembros perdidos hacia el centro de la celda. Cabe destacar que esta acumulación de estrellas se encuentra en la línea de la vía láctea, por lo cual la posibilidad de que se trate de un falso positivo aumenta considerablemente.



Figura 5: Mapa estelar en ascensión recta y declinación. Las regiones 65 y 66 corresponden a Hyades y COMA, donde se observan unos cúmulos bien definidos.




Figura 4: Resultados obtenidos para COMA(cluster 0). Se observan una excelente distribución en distancia, una buena secuencia principal de CMD y una buena distribución de VPD. Asimismo, se observa un segundo cluster que podría ser parte de COMA.




Figura 6: Resultados obtenidos en el cuadrante 19. Se ve una gran cantidad de ruido e el CMD, así como una secuencia principal con muchos vacíos, pero una buena coherencia en el VPD. La distribución en distancia no tiene la forma gaussiana esperada, y supera los 30 parsecs de extensión. Está centrado cerca a los 85 parsecs de distancia.




Figura 7: Resultados obtenidos en el cuadrante 20. Se observa una gran cantidad de ruido en el CMD, con pocos miembros que parecen reales, un VPD muy disperso y una distribución espacial de dos picos diferentes, poco coherentes para la distribución esperada de un cúmulo real. Está centrado hacia los 62 parsecs de distancia del sol.




Figura 9: Resultados obtenidos en el cuadrante 7. Vemos secuencias principales completas, con VPDs compactos. Sin embargo, es notable que el primer cúmulo presenta una buena distribución en distancia mientras que el cúmulo 0 parece estar esperando a la otra mitad de su población por fuera de los 100 pársecs.




Figura 8: Resultados obtenidos en el cuadrante 44. Se observa una gran cantidad de ruido en el CMD para ambos cúmulos, aunque tienen una distribución coherente en el VPD. Sin embargo, el cúmulo 3 tiene una mala distribución en distancia, con muchos picos y valles, mientras que el primero goza de una distribución mejor.




Figura 10: Resultados obtenidos para la región 14. Vemos un cúmulo con mucho ruido y huecos en la secuencia principal, un VPD compacto y una distribución en distancia con varios picos locales.




Figura 11: Resultados obtenidos para la región 19. Se observa un CMD con mucho ruido y una secuencia principal poco poblada, así como una distribución en distancia superior a 30 pársecs con un par de picos locales cerca de los 95 y los 80 pársecs.




Figura 13: Resultados obtenidos para el cuadrante 22. Se observa poco ruido en el CMD, con una buena secuencia principal, un VPD relativamente centrado, y una buena distribución en extensión, pegada a los 100 pársecs.




Figura 12: Resultados obtenidos para el cuadrante 20. Se observa una gran cantidad de ruido en el CMD, un VPD poco poblado y diversos picos en la distribución en distancia, cada vez mayores mientras crece la distancia.




Figura 14: Resultados obtenidos para el cuadrante 25. El CMD tiene poco ruido, pero una secuencia principal gruesa. El VPD es disperso y la distribución en distancia es ascendente con algunos vacíos.




Figura 15: Resultados obtenidos para el cuadrante 31. El CMD tiene muy poco ruido, y la secuencia principal es coherente, pero tiene picos locales y huecos en su distribución en distancia.




Figura 17: Resultados obtenidos para el cuadrante 42. De secuencia principal gruesa y CMD con poco ruido, un VPD disperso pero coherente y una distribución en distancia que parece ser el principio de un cúmulo.




Figura 16: Resultados obtenidos para el cuadrante 39. Su CMD presenta poco ruido y una buena secuencia principal, con un VPD compacto y una distribución en distancia cercana a los 100 pársecs pero coherente con la de un cúmulo real.




Figura 18: Resultados obtenidos para el cuadrante 44. Dos cúmulos que parecen estar compuestos por puro ruido e el CMD, aunque tengas VPDs compactos. La distribución en distancia del cúmulo 3 muestra una estructura con muchos picos y valles, mientras que la del primero muestra un histograma más coherente con el de un cúmulo real.




Figura 19: Resultados obtenidos para el cuadrante 47. Con un poco de ruido, una secuencia principal gruesa y un VPD compacto. La distribución en distancia parece tener dos regiones principales de picos, en 85 y 97 pársecs.




Figura 21: Resultados obtenidos para el cuadrante 51. Presenta dos cúmulos que podrían ser uno de no ser por su separación en el VPD. Ambos tienen buen CMD y una distribución buena en distancia.




Figura 20: Resultados obtenidos para el cuadrante 48. una secuencia principal fina, con un VPD compacto y coherente, y una distribución en distancia con dos regiones de picos, sobre 92 y 96 pársecs, con un valle entre medias.




Figura 22: Resultados obtenidos para el cuadrante 52. Con una secuencia principal poco poblada, pero con muy poco ruido en el CMD. Un VPD disperso y una distribución en distancia con valles y picos.




Figura 23: Resultados obtenidos para el cuadrante 62. Presenta una secuencia principal con muchos huecos y un CMD con una cantidad de ruido no menor. Su VPD es medianamente compacto, y su distribución en distancia es muy buena.