

Estrellas variables y Machine Learning

Trabajo con métodos de machine learning para la correcta identificación de estrellas variables

Proyecto final del curso

Bruno Abello Laurent¹

¹Universidad de Los Andes, Departamento de Física, Colombia

Correo institucional: b.abello@uniandes.edu.co
Repositorio de GitHub: Repositorio del laboratorio

Resumen

El siguiente informe presenta un trabajo de desarrollo de features y clases para un análisis de datos de OGLE etiquetados. Se detallan el proceso y las razones de uso de las mismas, así como su introducción al algoritmo de Random Forests para obtener datos numéricos sobre la clasificación aprendida de estas estrellas. Se obtiene un porcentaje de predicción acertada del 92.17 por ciento, y se discuten las razones por las que las features fallaron o cumplieron, así como los caminos que puede tomar un trabajo futuro, enfocado especialmente en la aclaración de lo que se encuentra en la etiqueta que OGLE pone sobre un gran número de estrellas: Others. Al ser un cierre de ciclo académico, este informe presenta una mirada hacia el futuro más propositiva que en otras entregas debido a los intereses personales del autor y a su periodo de entrenamiento en la Astrofísica Observacional.

Palabras clave: Estrellas variables, Random Forests, Dataset etiquetado, Features no correlacionadas, Matrices de confusión

1 Introducción

La astrofísica observacional moderna es probablemente una de las ramas de la física que menos se parece a lo que era hace cien años. Hoy en día, la mayor parte del tiempo de un astrofísico corriente transcurre frente a una pantalla con un proyecto de Machine learning en curso. Aunque sea un método extremadamente popular actualmente, lo cierto es que esta es una de las herramientas más confiables del físico, ya que dada la lógica correcta, esta es la manera más rápida y más efectiva de tratar los miles de datos que capturan los telescopios modernos, y que se hacen públicos gracias al formato informático.

Este es el último en una serie de once informes planeados sobre la astrofísica. La idea de esta serialización es servir de aproximación a todo lo que hace un astrofísico moderno, desde las implementaciones de cómputo más básicas hasta los ejercicios de pensamiento más complejos que se tienen en el dominio. Después de pasar unas semanas hablando de cúmulos globulares, y utilizando un poco de machine learning para buscar cúmulos nuevos en la vecindad del Sol, pasamos a trabajar las estrellas variables: un análisis básico de algunos tipos de estrellas variables fue uno de los once trabajos realizados.

En este orden de ideas, este proyecto final trata las es-

trellas variables desde una perspectiva que no se había planteado en trabajos anteriores: ¿Y si no sabemos qué tipo de estrella tenemos en los datos? A esto se enfrentan los astrofísicos muy a menudo, puesto que un telescopio no puede decirnos qué es una estrella, sólo cómo se comporta. El trabajo de encontrar qué tipo de estrella tenemos es algo tedioso, en teoría. Ver su curva de luz, su comportamiento, pensar en si encontramos su periodo correcto o si se trata solamente de un error de la máquina, son cosas que nunca vamos a poder solucionar del todo.

Lo que sí podemos hacer es enseñarle a una máquina cómo se comportan las estrellas reales y decirle que clasifique una serie de datos por nosotros. Este es precisamente nuestro trabajo, entre estrellas eclipsantes, pulsantes, de largo periodo y estrellas no clasificadas. Gracias al algoritmo de Random Forests, y a unas 6000 estrellas repartidas entre set de entrenamiento y de clasificación, este trabajo presenta ventajas y desventajas del machine learning aplicado a la astrofísica observacional.

1.1 Objetivos

Los objetivos propuestos para este informe son los siguientes:

- Aprender a implementar un método de machine learning

ning con datos etiquetados.

- Aprender a leer los resultados de dicho método.
- Aprender a interpretar los resultados con el objetivo claro de mejorar la calidad de la información que trabaja el método.
- Aprender a pensar como astrofísico antes de implementar alguna función o método computacional para el análisis de datos.
- Entender por qué el conocimiento adquirido como físico es tan importante para el uso del machine learning y demás métodos computacionales.

2 Procedimiento

Este trabajo tuvo un proceder distinto a los anteriores. De las tres semanas que se trabajó, solo en los últimos días se hizo algo de machine learning. Las primeras dos semanas fueron de revisión de datos y de ideación de features para el método. Hacer un trabajo de estos no es una tarea sencilla, ya que se requiere de un gran conocimiento para entender qué es una buena feature independiente para un dataset específico. En este caso, todos los estudiantes empezamos con periodo, que luego se cambió por logaritmo de periodo, que parece separar mejor las estrellas, y luego tomamos color V-I. Adicionalmente, muchos optamos por utilizar skewness, ya que presenta mejores resultados que la kurtosis, y a modo personal se escogió la diferencia de fase entre un máximo y el siguiente mínimo.

Cada una de estas features se estudió cuidadosamente y se realizaron extensivas gráficas y comparaciones para determinar si eran features dignas de ser usadas. Esto sucedió principalmente con la feature personal, ya que la idea provino de que algunas estrellas variables tienen una curva de luz en dientes de sierra, y otras son más sinusoidales: si se pudiera capturar esta diferencia mediante el offset de la curva, tendríamos una feature potente. Sin embargo, se terminó tomando únicamente la separación entre un máximo y su siguiente mínimo ya que el contrario, y la diferencia entre mínimos para detectar estrellas binarias, no mostraron separación significativa entre las clases de estrellas.

Se realizaron gráficos 3D para comparar separaciones de estrellas según features, y se intentaron varias features que no se incluyeron en el método final.

3 Problemas presentados y soluciones aplicadas

1. Entender por qué algunas features son mejores que otras resultó bastante complicado, especialmente entender por qué features que parecen tan evidentes en una gráfica no se traducen a algo en el código.
2. Como se dijo, algunas features que parecían prometedoras no fueron utilizadas porque, a la hora de la

verdad, no representaban en números lo que se ve en un gráfico.


3. La feature de periodo presentó problemas con las estrellas eclipsantes, que tienen dos picos de distinta intensidad, y con las LPVs, que tienen un rango enorme de periodos. No hay una solución clara al respecto, puesto que para corregir el error hay que saber que se trata de una estrella de este tipo, así que se esperan más confusiones en estas categorías que en las demás.
4. Las iteraciones e intentos en el código lo volvieron bastante lento. El proceso de optimización fue demorado y muy encimado al tiempo de escritura de este informe, y algunas cosas quedaron evidenciadas de esto, como el hecho de que, cuando no se realiza una búsqueda especializada para el periodo de cada tipo de estrella, esta feature pasa a ser mucho menos importante.

4 Resultados

Puesto que este es un trabajo extenso, esta sección se divide en la parte del trabajo sobre features y el trabajo sobre los resultados.

4.1 Features

Empezamos el trabajo por filtrar algunas estrellas que representan clases muy marginales (Fig: 1). Luego, en vez de tomar el periodo que da OGLE para cada estrella, lo calculamos con Lomb Scargle y lo comparamos con el que da OGLE. Se ve que el 80 por ciento de las estrellas responde bien a este ajuste, mientras que el resto, especialmente estrellas eclipsantes y de periodo largo, no están dentro de un margen de aceptabilidad correcto.






Figura 2: Histograma mostrando la distribución de diferencias promedio entre mínimos y máximos de las estrellas. No hay ningún pico distinto de los demás, por lo que esta feature no nos conviene




Figura 3: Histograma mostrando la distribución de diferencias promedio en fase entre máximos y mínimos de las estrellas. Se ve que el pico de estrellas pulsantes difiere del resto, por lo que esta feature, aunque no sea tan definitiva como otras, nos puede servir.




Figura 4: Histograma mostrando la distribución de diferencias promedio en magnitud entre mínimos. Aún con la escala logarítmica se aprecia que ninguna clase está por fuera del pico de las demás, por lo que esta feature tampoco sirve. El resultado entre máximos es muy similar a este.

Acto seguido, buscando solucionar el problema de estas estrellas por otros medios, se extrae la diferencia entre mínimos y la distancia entre mínimos y máximos (Fig: 2, 3, 4). Los resultados, bastante pobres, nos dicen que podemos usar la diferencia entre un máximo y el siguiente




Figura 5: Histograma mostrando la distribución de skewness por clase. Aunque la mayoría son similares, se nota que las estrellas binarias destacan del resto.




Figura 6: Histograma mostrando la distribución de color por clase. Se ve que ninguna clase es igual, y que Others, aunque sangra a las demás clases, tiene su propio pico. Aunque no sea ideal que tenga varios, esto puede permitirnos pensar en las clases subyacentes de Others.

mínimo para separar las estrellas pulsantes del resto, pero que ningún otro feature va a ser importante saliendo de estos cálculos.

Por otro lado, la skewness de las clases nos permite diferenciar las estrellas binarias del resto (Fig: 5). Con el color, las cosas cambian, ya que cada clase tiene un pico de color definido, y la clase others, aunque tenga miembros en todo el espectro, no emborrona mucho a ninguna de las clases bien definidas (Fig: 6). Comparándolas en gráficos de 3 dimensiones, que se ve mucho mejor en el código subido al repositorio, vemos que cada clase está bien separada, mientras que las Other sangran entre las clases. Con todo esto, aplicar machine learning es posible, ya que tenemos como diferenciar binarias y pulsantes de manera especializada, y gracias al periodo y al color, las LPV se diferencian de estas.

Queda claro, por último, que separar las Others va a ser complejo y que van a ser la clase más problemática. Más que preocuparnos por esto, nos tenemos que preocupar por que el trabajo funcione correctamente con las demás clases y luego empezar a revisar la clase Others particularmente para conocer sus características, como el doble pico en color, y poder clasificar sus estrellas de mejor manera.

4.2 Machine Learning

Buscando cómo implementar un código que no demorara una hora corriendo, se realizaron bastantes recortes, notablemente ya ninguna estrella tenía una búsqueda de periodo especializada, por lo que esta feature dejó de ser importante y es posible que varias de estas estrellas tengan un periodo incorrecto. Lo principal, sin embargo, es que los resultados con un dataset de entrenamiento grande, o sea 5364 estrellas de entrenamiento de las 6705, se obtienen resultados supremamente positivos: 92.17 porciento de predicción correcta, con el más bajo, de 85 porciento, en las Others. La matriz de confusión muestra que lo más complejo fue predecir las binarias, ya que unas 45 fueron mal clasificadas, mientras que las pulsantes y LPVs cuentan con 10 o menos errores (Fig: 7).




Figura 7: Matriz de confusión del testeo de un grupo de poco más de mil estrellas después de un entrenamiento con más de cinco mil. Vemos que la predicción que más errores dió fue predecir que era una Other cuando se trataba de una binaria, y que las pulsantes y LPVs fueron muy bien predichas.




Figura 8: Matriz de confusión del testeo de un grupo de más de cinco mil estrellas, con un entrenamiento de unas mil. Una vez más, es de resultados bastante lineales, donde lo más notable es la confusión entre binarias y others, y las confusiones de varios tipos con binarias.

Luego, se invirtieron los roles, y se entrenó con 20 porciento del dataset. Esta vez, el porcentaje de predicción fue del 90.81, y de nuevo la precisión más baja se la llevan las Others con 83 porciento. La matriz de confusión, igual que antes, muestra que las binarias fueron las más complejas de predecir, las pulsantes las más sencillas, y que binarias y others son las que más se confunden (Fig: 8).




Figura 9: Importancia de cada feature en la clasificación del testing de 1000 estrellas. Se ve una clara dominación del color, y vemos que el periodo no resulta ser tan efectivo como lo esperábamos al iniciar el laboratorio. Con nuestras expectativas después de calcularlo sin discriminación, este resultado es más lógico.




Figura 10: Importancia de cada feature en la clasificación del testing de 5000 estrellas. Skewness y La diferencia entre máximos y mínimos cobra mucha importancia cuando el modelo no sabe a ciencia cierta que con color puede discernir los grupos mucho mejor. Se ve que la idea original del autor sirve un propósito, aunque este decaiga con el entrenamiento correcto del modelo.

Lo más notable de estos intentos es, como ya se mencionó anteriormente, que el periodo disminuyó ampliamente en su importancia. Esto se ve reflejado en que la categoría más difícil de clasificar resulta ser la clase binaria: no es de sorprendernos, ya que al ser víctima de alias y de problemas de caracterización con Lomb Scargle, puesto que este no distingue sus eclipses como diferentes, simplemente como oscilaciones de diferente amplitud pero que corresponden al mismo fenómeno, el periodo que se encuentra para una binaria es posiblemente incorrecto. Sin embargo, este no es el único fenómeno interesante. Al invertir los porcen-

tajes, y entrenar con menos estrellas, todas las features se encuentran en el mismo nivel de importancia (Fig: 10), mientras que para un algoritmo mejor entrenado había una clara victoria del color sobre las demás features (Fig: 10). Esto sucede porque el color es el discriminador más drástico, como habíamos predicho, mientras que la skewness y el MaxMin son más tajantes cuando hay ruido o no se ha aprendido a discriminar tan correctamente.

Cabe destacar, evidentemente, que estos son los resultados de una repetición del experimento, y que los resultados pueden variar ligeramente. Es importante también ver que la distribución de confianza de clasificación es bastante extensa, pero que muestra una dominancia robusta de la confianza casi absoluta (Fig: 11, 12). Como es de esperar, se nota que un modelo menos entrenado confía menos en sus resultados que uno bien entrenado, y se nota que el set menos entrenado clasifica más datos.




Figura 11: Distribución de confianza de la clasificación de 1000 estrellas testeadas, en escala logarítmica vertical. Se ve una clara tendencia a tener estrellas con una clasificación de alta confianza.




Figura 12: Distribución de confianza de la clasificación de 5000 estrellas testeadas, en escala logarítmica vertical. Se ve una tendencia hacia las probabilidades altas de buena clasificación, aunque la cola de probabilidades inferiores se empieza a llenar bastante.

4.3 Comentarios sobre los resultados

Más allá de la exposición de los resultados obtenidos, está claro que las cosas se hicieron bien a nivel astrofísico.

Agrupando las estrellas en estos cuatro grupos, y tomando features no correlacionadas, de mucho impacto y pocas en cantidad, tenemos resultados sencillos de leer, confiables y, en su mayoría, correctos. Si bien los números no son del 99.99 por ciento, y no se hizo un trabajo sobre cada tipo de estrella y cada feature posible, este trabajo demuestra que, a pesar de que el machine learning pueda parecer una caja negra que resuelve problemas, la única manera de presentar resultados comprensibles y fundamentados es pensando más en cómo alimentar a la máquina que en cómo interpretar lo que dice.

Dejando esta nota positiva al margen, quedan un par de reflexiones por hacerse. Lo primero es que sí, el machine learning funcionó muy bien para clasificar estrellas, pero para poner una etiqueta en un dataset lo mejor es que siempre lo revise un humano. De lo contrario, esas 33 binarias clasificadas como Others se van convirtiendo en más y más binarias que terminan en Others, y al final nuestro dataset está compuesto por Otro Tipo de Estrellas, algo que no va a tener sentido físico y que va a ser un lío de desenmarañar.

Seguido a esto: ¿Cómo clasificamos las Others? Está claro que no necesitamos periodo para clasificar binarias, y que con un par de features todo queda más o menos guardadito. Las Others siguen siendo un problema, ya que plagan nuestros datasets, al no pertenecer a ninguna categoría, todas son bienvenidas. En ese sentido, solo hay un camino a seguir, y es responder más preguntas: ¿Qué son las estrellas Others mal clasificadas? ¿Actúan de verdad como lo hace esta clase? Aquí, se puede aplicar un análisis especializado para dicha clase y encontrar una solución: Sí, son este tipo de estrellas, o no, por aquí no es el camino. ¿Y con las Others que quedan? Bueno, o son grupos de una, o cinco estrellas, va a ser difícil que la máquina aprenda a clasificarlas con argumentos físicos razonables. O realizamos machine learning no supervisado para que las separe en grupos y las analicemos por grupos, o las revisamos una a una buscándoles un sentido y una pertenencia. Eso si queremos clasificarlas todas.

Si preferimos buscar un tipo de estrellas (el lector está familiarizado con las estrellas Be de sobremanera), podemos buscar algunos comportamientos selectivamente, como la forma de su curva de luz, o superposiciones de periodos, entre la formación de su disco de material, su interacción con su estrella hermana si la tiene, y sus oscilaciones rapidísimas. En nuestro caso, podríamos pensar en explorar la separación de color tan curiosa que se vió (Fig: 6). Seguramente ahí hay dos grupos discernibles, y de esos dos grupos podemos explorar subgrupos con menos ruido alrededor.

5 Conclusiones

Este estudio marca el final de una etapa: las conjeturas del autor dejan de ser conjeturas y pasan a tomar un valor físico relevante en las discusiones sobre el tema. Por mucho que se quiera seguir en etapa de entrenamiento, lo cierto es

que el bagaje adquirido y la curiosidad humana se tienen que juntar para pensar, seriamente, en qué hay más allá de lo que unas ruedas de entrenamiento permiten ver.

Sí, los números de confianza y de correlación obtenidos son buenos, y sí, las features y clases pensadas a través de discusiones en el aula y conversaciones con uno mismo funcionaron, pero eso no significa que podamos quedarnos tranquilos, ya que aún no sabemos qué son las Others, por qué actúan así, qué features nos permiten atacar sus particularidades, y ¿cómo hacer, si no es mediante el ensayo y el error, para estar seguros de que nuestras conjeturas sobre lo que hay ahí son correctas?. Además, sin ir tan lejos podemos preguntarnos si los resultados obtenidos no podrían ir más allá, si confiar en el etiquetado de OGLE o no, y si no hay maneras de convertir el periodo en una feature más relevante.

Lo cierto es que todo apunta a que hay que seguir adelante. Solo ir a observar las estrellas nos puede confirmar que esas 33 Others son binarias particulares, y solo ir a molestar a los datos y a intentar clasificarlos nos puede revelar la verdadera naturaleza de esas estrellas, ya sea con machine learning o con análisis humano extensivo. De cualquier forma, solo se puede concluir que un trabajo mal hecho invita a rearmarlo, y un trabajo bien hecho invita a profundizarlo.

Comentarios al margen

Mientras realizaba el análisis, recordé una discusión en el aula: el machine learning nos sirve para aprender una situación, y al cambiar el dataset y el entorno, no va a servir de nuevo. Eso, entonces, ¿implica que el estudiante podría descargar gigas de datos de OGLE y pasarlas por este algoritmo? ¿Sería esto positivo para esclarecer quiénes están en Others mediante un machine learning no etiquetado?